Στατιστική Μοντελοποίηση και Αναγνώριση Προτύπων 2023-2024 (ΤΗΛ311)

Εργασία 1

Φοιτητής 1: Αργύρης Γεώργιος 2020030138

Φοιτητής 2: Αλεξίου Σταμάτιος 2020030158

19/05/2024

Θέμα 1: Principal Component Analysis (PCA)

Μέρος 1

Αρχικά, τρέχοντας το αρχείο ex1_2_pca.m διαβάσαμε το αρχείο 'breast_cancer_data.csv' Επιλέξαμε δύο διαφορετικά ζεύγη χαρακτηριστικών και απεικονίσαμε τα δείγματα στον 2D χώρο, χρησιμοποιώντας διαφορετικό χρώμα για κάθε κατηγορία. Παρατηρούμε πως οι κλάσεις διαφοροποιούνται ανάλογα με τα ζεύγη των χαρακτηριστικών. Τα χαρακτηριστικά 29,30 αποτελούν “bad” features.

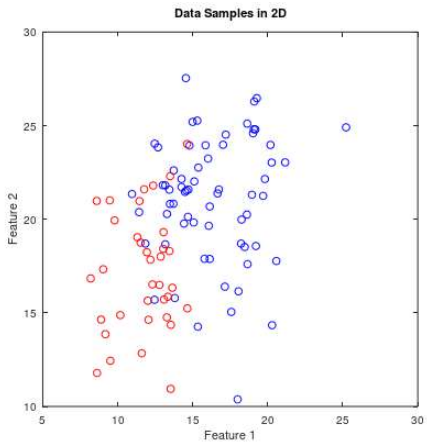

First Two Features (1,2)

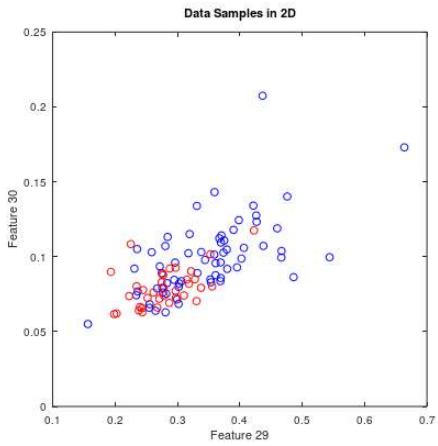

Last Two Features (29,30)

Στην συνέχεια, προχωρήσαμε με τα πρώτα δύο χαρακτηριστικά και εφαρμόσαμε standardization στα αρχικά δείγματα συμπληρώνοντας το αρχείο featureNormalize.m και σχεδιάσαμε τα κανονικοποιημένα δείγματα σε διαφορετική εικόνα.

```
function [X_norm, mu, sigma] = featureNormalize(X)
%FEATURENORMALIZE Normalizes the features in X
%   FEATURENORMALIZE(X) returns a normalized version of X where
%   the mean value of each feature is 0 and the standard deviation
%   is 1. This is often a good preprocessing step to do when
%   working with learning algorithms.

% Initialization of variables %
[m, n] = size(X);
X_norm = zeros(m, n);
mu = zeros(1, n);
sigma = zeros(1, n);

% Calculate the mean of each feature %
mu = mean(X);

% Calculate the standard deviation of each feature %
sigma = std(X);

X_norm = zeros(size(X));

% Normalize the features in X %
X_norm = (X - mu) ./ sigma;

% ============================================================

end
```

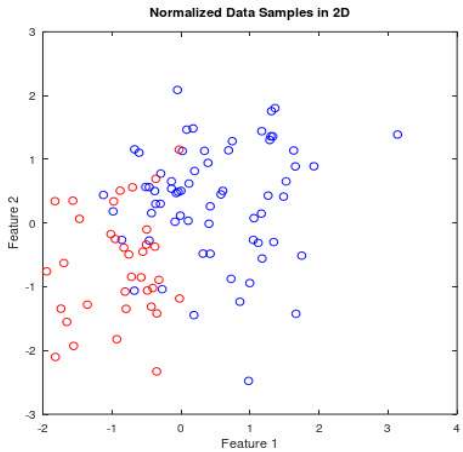

Μετά το standardization, παρατηρούμε ότι τα δείγματα βρίσκονται κυρίως γύρο από το 0 καθώς το 0 θα είναι το κέντρο, ενώ η διασπορά τους θα ισούται με 1.

Έπειτα, υπολογίσαμε τις κύριες συνιστώσες του αλγορίθμου PCA και τις σχεδιάσαμε στην ίδια εικόνα μαζί με τα αρχικά δείγματα συμπληρώνοντας το κώδικα στο αρχείο myPCA.m.

Η πρώτη κύρια συνιστώσα είναι η κατεύθυνση της μέγιστης διακύμανσης από το σημείο μηδέν, ενώ οι δεύτερες κύριες συνιστώσες είναι ορθογώνιες προς την πρώτη κύρια συνιστώσα και περιγράφουν τη μέγιστη υπολειπόμενη διακύμανση.

```
function [ eigenval, eigenvec, order] = myPCA(X)
%PCA Run principal component analysis on the dataset X
%   [ eigenval, eigenvec, order] = mypca(X) computes eigenvectors of the autocorrelation matrix of X
%   Returns the eigenvectors, the eigenvalues (on diagonal) and the order
%

% Useful values
[m, n] = size(X);

% Make sure each feature from the data is zero mean
X_centered = X - mean(X);

% ====================== YOUR CODE HERE ======================

% Compute the covariance matrix
covariance_matrix = (1 / m) * (X_centered' * X_centered);

% Compute the eigenvectors and eigenvalues of the covariance matrix
[eigenvec, eigenval] = eig(covariance_matrix);

% Sort eigenvalues in descending order
[eigenval, order] = sort(diag(eigenval), 'descend');
eigenvec = eigenvec(:, order);

% =========================================================================
end
```

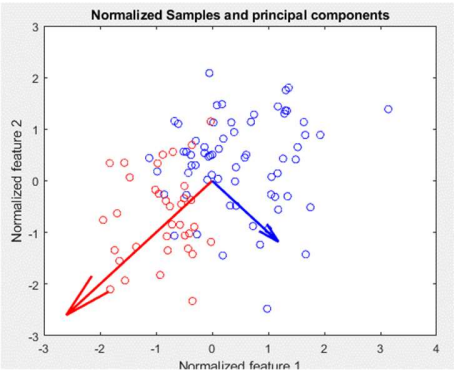

Στην συνέχεια, υπολογίσαμε τις προβολές των δεδομένων στις κύριες συνιστώσες του αλγορίθμου PCA και σχεδιάσαμε τις προβολές αυτές σε ένα δισδιάστατο χώρο όπως φαίνεται παρακάτω.

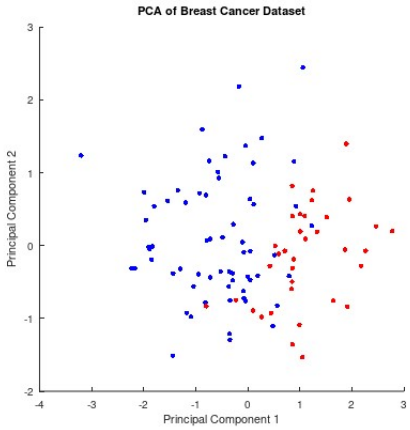

Έπειτα, υπολογίσαμε την συνεισφορά όπου έχει κάθε κύρια συνιστώσα (explained variance) στην συνολική διακύμανση με τον τύπο: $Var(PCi) = \frac{\lambda i}{\sum_{j=1}^{L} \lambda j}$.

```
Explained Variance(1st PC = 0.687891) (2nd PC = 0.312109)
1st Principal Component = -0.707107 -0.707107
```

Οπότε η 1η κύρια συνιστώσα κρατάει το 68.8% της πληροφορίας, ενώ η 2η διατηρεί το 31.2%.

Η 2η κύρια συνιστώσα μας δίνει το λιγότερο σημαντικό πρότυπο στα δεδομένα, όπου όλα τα σημεία ακολουθούν την κύρια γραμμή, αλλά είναι εκτός της κύριας γραμμής κατά κάποιο ποσό.

Στην συνέχεια, εφαρμόσαμε τον αλγόριθμο PCA στα δείγματα για να μειώσουμε τη διάστασή τους από 2D σε 1D συμπληρώνοντας τον κώδικα στο projectData.m.

```
function Z = projectData(X, U, K)
%PROJECTDATA Computes the reduced data representation when projecting only
%on to the top k eigenvectors
%   Z = projectData(X, U, K) computes the projection of
%   the normalized inputs X into the reduced dimensional space spanned by
%   the first K columns of U. It returns the projected examples in Z.
%

% You need to return the following variables correctly.
Z = zeros(size(X, 1), K);

% ===================== YOUR CODE HERE =====================
% Instructions: Compute the projection of the data using only the top K
%               eigenvectors
%

Z = X * U(:, 1:K);

% =============================================================

end
```

Αφού προβάλλαμε τα δεδομένα σε χώρο μικρότερων διαστάσεων, προσπαθήσαμε να ανακτήσουμε προσεγγιστικά τα δεδομένα αναπαράγοντάς τα ξανά στον αρχικό χώρο υψηλών διαστάσεων (2D) υλοποιώντας το recoverData.m.

```
function X_rec = recoverData(Z, U, K)
%RECOVERDATA Recovers an approximation of the original data when using the
%projected data
%   X_rec = RECOVERDATA(Z, U, K) recovers an approximation the
%   original data that has been reduced to K dimensions. It returns the
%   approximate reconstruction in X_rec.
%

% You need to return the following variables correctly.
X_rec = zeros(size(Z, 1), size(U, 1));

% ===================== YOUR CODE HERE =====================
% Instructions: Compute the approximation of the data by projecting back
%               onto the original space using the top K eigenvectors in U.
%
%

X_rec = Z * U(:,1:K)';

% =============================================================

end
```

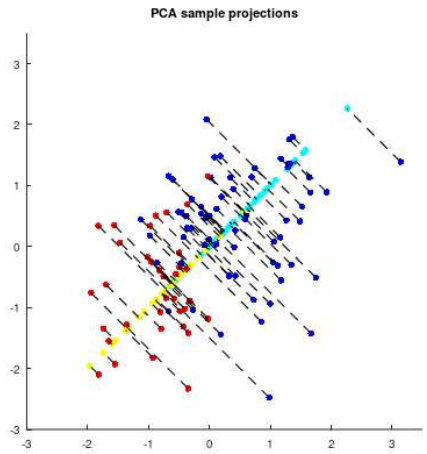


```
Projection of the first example: 1.058683
Approximation of the first example: -0.748602 -0.748602
```

Τέλος, επαναλάβαμε την ανάλυση PCA χρησιμοποιώντας αυτή τη φορά όλο το διάνυσμα χαρακτηριστικών επιλέγοντας τις δύο πρώτες κύριες συνιστώσες και σχεδιάσαμε την προβολή των δειγμάτων σε αυτές.

```
Explained Variance(1st PC = 0.430518) (2nd PC = 0.207239)
1st Principal Component = 0.206988 0.106123
```

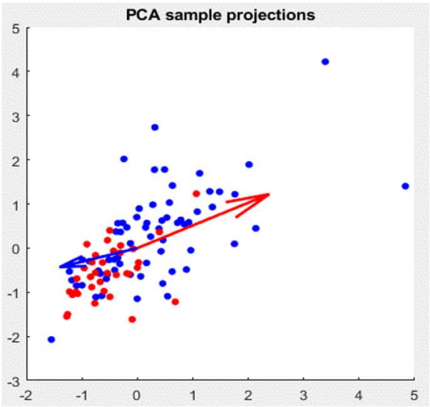

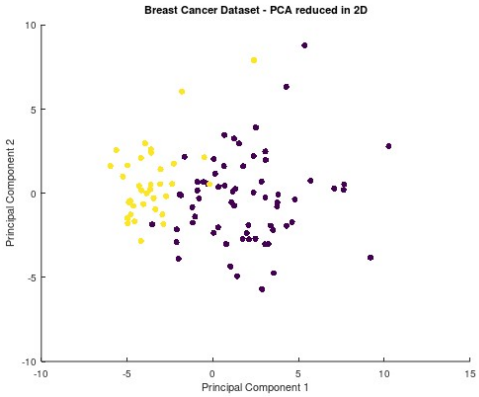

Παρατηρούμε ότι τα ιδιοδιανύσματα έχουν διαφορετική κατεύθυνση σε σχέση με το ερώτημα β. Αυτό συμβαίνει επειδή έχουν προστεθεί όλα τα χαρακτηριστικά, γεγονός που οδηγεί σε αλλαγή της διασποράς και της μέσης τιμής των δεδομένων. Η προσθήκη νέων χαρακτηριστικών επηρεάζει τη δομή του πίνακα συνδιακύμανσης, αλλάζοντας τις συσχετίσεις μεταξύ των χαρακτηριστικών.

Μέρος 2

Επαναλάβαμε τα παραπάνω χρησιμοποιώντας τα δεδομένα 5000 εικόνων προσώπων που μας δόθηκαν στο αρχείο 'data\faces.mat'και σχεδιάσαμε τα πρώτα 100 πρόσωπα από το dataset χρησιμοποιώντας τη συνάρτηση displayData() που μας δίνεται.

Εφαρμόσαμε standardization πάνω στα δείγματα που έχουμε και ακολούθως υπολογίσαμε τις κύριες συνιστώσες και σχεδιάσαμε σε μια νέα εικόνα τις πρώτες 36 κύριες συνιστώσες που βρήκαμε με την συνάρτηση displayData().

Παρατηρούμε πως έχουν αφαιρεθεί οι λεπτομέρειες από το κάθε πρόσωπο και έχουν μείνει μόνο τα χαρακτηρίστηκα του κάθε προσώπου.

Έπειτα μειώσαμε την διάσταση των δειγμάτων χρησιμοποιώντας τις 100 πρώτες κύριες συνιστώσες με την projectData().

```
Dimension reduction for face dataset.

The projected data Z has a size of: 5000 100
```

Τέλος, σχεδιάσαμε τα δείγματα μειωμένης διάστασης αφού πρώτα τα προβάλαμε στον αρχικό χώρο.

Παρατηρούμε πως υπάρχει μικρή απόκλιση μεταξύ των αρχικών και των ανακτημένων προσώπων γεγονός που οφείλεται στην επιλογή του αριθμού των συνιστωσών K.

Επαναλάβαμε την διαδικασία χρησιμοποιώντας διαφορετικές τιμές K:

1. K = 10

2. K = 50

3. K = 200

Με βάση τα παραπάνω, παρατηρούμε ότι όσο αυξάνουμε τον αριθμό των συνιστωσών, τα δείγματα μειωμένης διάστασης που έχουν προβληθεί στον αρχικό χώρο, μοιάζουν ακόμα περισσότερο με τα αρχικά δείγματα.

Θέμα 2: Σχεδιάστε ένα ταξινομητή LDA (Linear Discriminant Analysis)

Δεδομένα : $P(\omega_A) = 0.4$, $\mu_A = \begin{bmatrix}0\\2\end{bmatrix}$, $\mu_B = \begin{bmatrix}2\\0\end{bmatrix}$, $\Sigma_A = \begin{bmatrix}3 & 1\\1 & 2\end{bmatrix}$, $\Sigma_B = \begin{bmatrix}2 & 1\\1 & 3\end{bmatrix}$

Έχω αρχικά : $P(\omega_B) = 1 - P(\omega_A) = 0.6$

Γνωρίζω ότι : $\sum w = \sum_{i=0}^{c} Pi\Sigma i$

Συνεπώς : $\Sigma_N = 0.4\Sigma_A + 0.6\Sigma_B = \Sigma_N = (0.4\begin{bmatrix}3 & 1\\1 & 2\end{bmatrix} + 0.6\begin{bmatrix}2 & 1\\1 & 3\end{bmatrix}) = \begin{bmatrix}2.4 & 1\\1 & 2.6\end{bmatrix}$

Σύμφωνα με τον τύπο : $\begin{bmatrix}a & b\\c & d\end{bmatrix}^{-1} = \frac{1}{ad-bc}\begin{bmatrix}d & -b\\-c & a\end{bmatrix}$ έχω :

$\begin{bmatrix}2.4 & 1\\1 & 2.6\end{bmatrix} = \frac{1}{5.24}\begin{bmatrix}2.6 & -1\\-1 & 2.4\end{bmatrix} = (\sum w)^{-1}$

Επομένως γνωρίζω ότι :

$$w = (\sum w)^{-1}(\mu_A - \mu_B) = \frac{1}{5.24}\begin{bmatrix}2.6 & -1\\-1 & 2.4\end{bmatrix}\left(\begin{bmatrix}0\\2\end{bmatrix} - \begin{bmatrix}2\\0\end{bmatrix}\right) = \begin{bmatrix}\frac{2.6}{5.24} & -\frac{1}{5.24}\\-\frac{1}{5.24} & \frac{2.4}{5.24}\end{bmatrix} * \begin{bmatrix}-2\\2\end{bmatrix} = \frac{1}{5.24}\begin{bmatrix}-7.2\\6.8\end{bmatrix}$$

Προκειμένου να υπολογίσω την προβολή των παρακάτω διανυσμάτων στον άξονα που ορίζεται από το διάνυσμα w πολλαπλασιάζω κάθε δείγμα με w.

Δείγματα : $\chi_A = \begin{bmatrix}1\\3\end{bmatrix}$ και $\chi_B = \begin{bmatrix}3\\-1\end{bmatrix}$

Έχω λοιπόν :

$$y_A = \frac{w^T Xa}{||w||} = \frac{\begin{bmatrix}-\frac{7.2}{5.24} & \frac{6.8}{5.24}\end{bmatrix}\begin{bmatrix}1\\3\end{bmatrix}}{1.82328} = \frac{2.22137}{1.82328} \approx 1.21836$$

και

$$y_B = \frac{w^T Xb}{||w||} = \frac{\begin{bmatrix}-\frac{7.2}{5.24} & \frac{6.8}{5.24}\end{bmatrix}\begin{bmatrix}3\\-1\end{bmatrix}}{1.82328} = -\frac{5.32061}{1.82328} \approx -2.91815$$

Θέμα 3: Linear Discriminant Analysis (LDA) vs PCA

Μέρος 1

Αρχικά, φορτώσαμε τα δείγματα ως εξής: load('data\data2.mat') και δημιουργήθηκαν οι μεταβλητές c που περιέχει την κλάση και η X που περιέχει τα χαρακτηριστικά διανύσματα.

Στην συνέχεια, κάναμε standardization (κανονικοποίηση με μ = 0 και σ = 1) χρησιμοποιώντας τη συνάρτηση featureNormalize που είχαμε φτιάξει για το Θέμα 1. Τα δείγματα της κάθε κλάσης σχεδιάστηκαν με διαφορετικό χρώμα στην ίδια εικόνα.

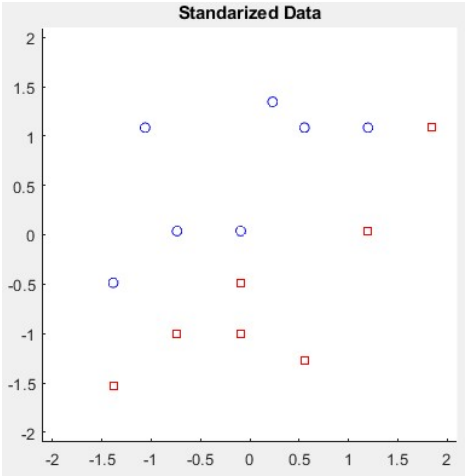

Προσθέσαμε τον απαραίτητο κώδικα στο αρχείο «fisherLinearDiscriminant.m» έτσι ώστε αυτό να υλοποιεί τον αλγόριθμο LDA για προβλήματα 2 κλάσεων.

```
function v = fisherLinearDiscriminant(X1, X2)
    % Compute the mean vectors for each class
    mu1 = mean(X1);
    mu2 = mean(X2);

    % Compute the within-class scatter matrices
    S1 = cov(X1);
    S2 = cov(X2);

    % Compute the within-class scatter matrix
    Sw = (S1 + S2)/2;

    % Compute the optimal direction for maximum class separation
    v = inv(Sw) * (mu1 - mu2)';

    % Normalize the vector to have unit norm
    v = v / norm(v);
end
```

Μετά την εκτέλεση της συνάρτησης fisherLinearDiscriminant με την χρήση του drawLine έχουμε:

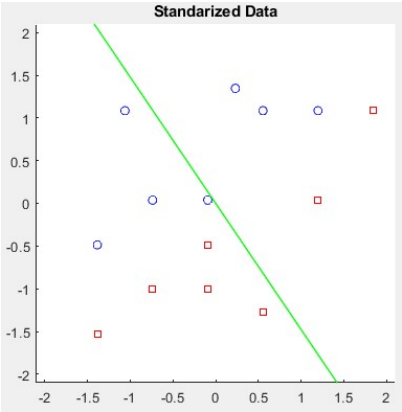

Έπειτα προσθέσαμε και τον κατάλληλο κώδικα στο αρχείο «projectDataLDA.m» ώστε τρέχοντας τη συνάρτηση να δημιουργούμε δείγματα μειωμένης διάσταση (1D).

```
function [Z] = projectDataLDA(X, v)

% You need to return the following variables correctly.
Z = zeros(size(X, 1), 1);

% ====================== YOUR CODE HERE ======================
Z=X*v;

% ============================================================

end
```

Προσθέσαμε τον κατάλληλο κώδικα στο αρχείο «recoverDataLDA.m» ώστε να κάνουμε ανακατασκευή των δειγμάτων μειωμένης διάστασης στον 2D χώρο προβάλλοντας τα πάνω στην κατεύθυνση του διανύσματος προβολής LDA. Σχεδιάσαμε πάνω στην ίδια εικόνα τα δείγματα μειωμένης διάστασης όπως προβάλλονται στον 2D χώρο μαζί με τα αρχικά μας δείγματα.

```
function [X_rec] = recoverDataLDA(Z, v)

% You need to return the following variables correctly.
X_rec = zeros(size(Z, 1), length(v));

% ====================== YOUR CODE HERE ======================

X_rec = Z*v';

% ============================================================

end
```

Μετά την εκτέλεση των παραπάνω συναρτήσεων, σχεδιάστηκαν τα δείγματα μειωμένης διάστασης μαζί με τα αρχικά δείγματα όπως προβάλλονται στον 2D χώρο, όπως φαίνεται και στην παρακάτω εικόνα.

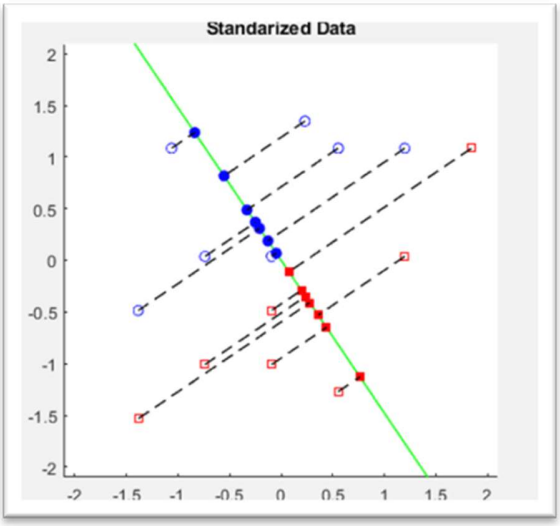

Εφαρμόσαμε την αντίστοιχη διαδικασία μείωσης διάστασης με τη μέθοδο PCA όπως την εφαρμόσαμε στο θέμα 1. Σχεδιάσαμε τα δείγματα που προκύπτουν με τη μέθοδο PCA παρακάτω.

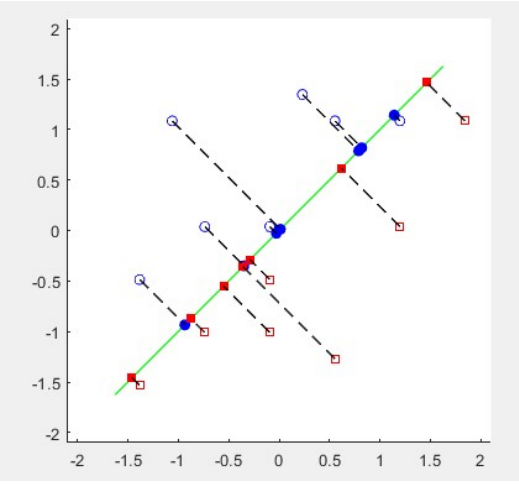

Από τα παραπάνω αποτελέσματα, βλέπουμε ότι με τον αλγόριθμο LDA παρατηρείται ένας εμφανής διαχωρισμός ανάμεσα στις κλάσεις. Σε αντίθεση, με τον αλγόριθμο PCA στο ίδιο dataset, τα χαρακτηριστικά επικαλύπτονται, με αποτέλεσμα να μην είναι δυνατή η διάκριση μεταξύ των δύο κλάσεων.

Μέρος 2

Αρχικά, φορτώσαμε τα δείγματα iris ως εξής: load('fisheriris.mat') εφαρμόσαμε standardization στα δείγματα και ακολούθως σχεδιάσαμε τα 2 πρώτα χαρακτηριστικά (features) σε ένα 2D γράφημα χρησιμοποιώντας ξεχωριστά χρώματα για κάθε κλάση.

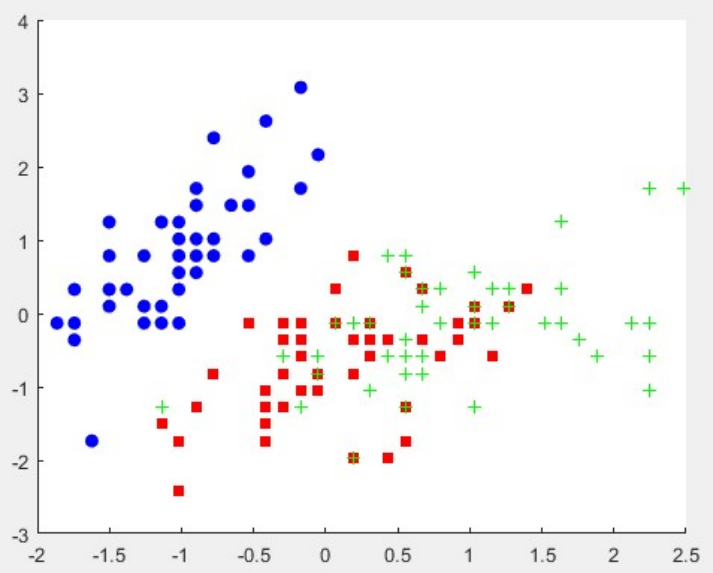

Έπειτα, προσθέσαμε τον απαραίτητο κώδικα στη συνάρτηση myLDA ο οποίος απεικονίζεται παρακάτω.

```
function A = myLDA(Samples, Labels, NewDim)
% Input:
%   Samples: The Data Samples
%   Labels: The labels that correspond to the Samples
%   NewDim: The New Dimension of the Feature Vector after applying LDA

    [NumSamples ,NumFeatures] = size(Samples);
    NumLabels = length(Labels);
    if(NumSamples ~= NumLabels) then
        fprintf('\nNumber of Samples are not the same with the Number of Labels.\n\n');
        exit
    end
    Classes = unique(Labels);
    NumClasses = length(Classes)  %The number of classes

    % Initialize Sw and Sb matrices
    Sw = zeros(NumFeatures, NumFeatures);
    Sb = zeros(NumFeatures, NumFeatures);
    %For each class i
    % Initialize variables
    Sw = zeros(NumFeatures, NumFeatures);
    Sb = zeros(NumFeatures, NumFeatures);
    P = zeros(1, NumClasses);
    mu = zeros(NumClasses, NumFeatures);
```

```
%Find the necessary statistics
  for i = 1:NumClasses
      %Calculate the Class Prior Probability
    P(i)= sum(Labels == Classes(i))/NumClasses ;
      %Calculate the Class Mean
    mu(i,:)= mean(Samples(Labels == Classes(i),:));
      %Calculate the Within Class Scatter Matrix
    Sw = Sw + P(i)*cov(Samples(Labels == Classes(i),:));
      %Calculate the Global Mean
    m0= mean(Samples) ;

      %Calculate the Between Class Scatter Matrix
    Sb = Sb + P(i) * (mu(i,:) - m0)*transpose(mu(i,:) - m0);
  end
  %Calculate the Class Prior Probability


  %Eigen matrix EigMat=inv(Sw)*Sb
  EigMat = inv(Sw)*Sb;

  %Perform Eigendecomposition
  [U,S] = svd(EigMat);

  %Select the NewDim eigenvectors corresponding to the top NewDim
  %eigenvalues (Assuming they are NewDim<=NumClasses-1)
%% You need to return the following variable correctly.
A=U(:,1:NewDim);  % Return the LDA projection vectors
end
```

Τέλος, χρησιμοποιώντας τις συναρτήσεις που υλοποιήθηκαν για την εφαρμογή των διανυσμάτων προβολής της LDA και την μείωση της διάστασης σε 2 πάνω στα αρχικά δείγματα, σχεδιάστηκαν τα δείγματα σε ένα δισδιάστατο διάγραμμα όπως βλέπουμε και παρακάτω.

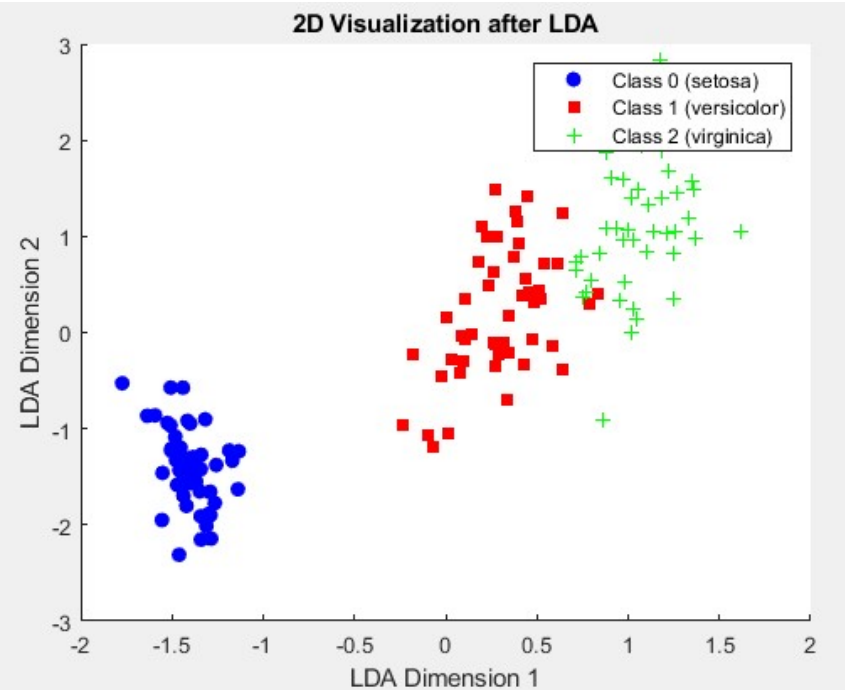

Θέμα 4: Bayes

<u>Δεδομένα</u>: ω_1, ω_2, $P(\omega_1)$, $P(\omega_1)$, $P(x|\omega_1) = \mathcal{N}(\mu_1, \mathbf{\Sigma}_1)$, $P(x|\omega 2) = \mathcal{N}(\mu_2, \mathbf{\Sigma}_2)$

$\mu_1 = \begin{bmatrix} 2 \\ 3 \end{bmatrix} => l = 2,\ \mathbf{\Sigma}_1 = \begin{bmatrix} 2 & 0.5 \\ 0.5 & 1 \end{bmatrix}$ $\qquad$ $\mu_2 = \begin{bmatrix} 4 \\ 4 \end{bmatrix} => l = 2,\ \mathbf{\Sigma}_2 = \begin{bmatrix} 1.5 & -0.3 \\ -0.3 & 0.8 \end{bmatrix}$

<u>Γνωρίζουμε από θεωρία ότι:</u>

$$p(x|\omega_1) = \frac{1}{(2\pi)^{\frac{2}{2}}|\Sigma 1|^{\frac{1}{2}}} exp(-\frac{1}{2}(x-\mu 1)^T \Sigma 1^{-1}(x-\mu 1))$$

$$p(x|\omega_2) = \frac{1}{(2\pi)^{\frac{2}{2}}|\Sigma 2|^{\frac{1}{2}}} exp(-\frac{1}{2}(x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2))$$

<u>Υπολογίζουμε:</u>

$\Sigma 1^{-1} = \frac{1}{1.75}\begin{bmatrix} 1 & -0.5 \\ -0.5 & 2 \end{bmatrix}$, $\Sigma 2^{-1} = \frac{1}{1.11}\begin{bmatrix} 0.8 & 0.3 \\ 0.3 & 1.5 \end{bmatrix}$ και $|\Sigma_1| = 1.75$ και $|\Sigma_2| = 1.11$

<u>Επίσης υπολογίζουμε:</u>

$$g_1 = -\frac{1}{2}(x-\mu 1)^T \Sigma 1^{-1}(x-\mu 1) + ln(P\omega 1) - \frac{l}{2}ln2\pi - \frac{1}{2}ln(|\Sigma 1|)$$

$$g_2 = -\frac{1}{2}(x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2) + ln(P\omega 2) - \frac{l}{2}ln2\pi - \frac{1}{2}ln(|\Sigma 2|)$$

<u>Decision Boundary:</u>

$g_1 = g_2$

$$-\frac{1}{2}(x-\mu 1)^T \Sigma 1^{-1}(x-\mu 1) + ln(P\omega 1) - \frac{l}{2}ln2\pi - \frac{1}{2}ln(|\Sigma 1|) = -\frac{1}{2}(x-\mu 2)^T \Sigma 2^{-1}(x-\mu 2) + ln(P\omega 2) - \frac{l}{2}ln2\pi - \frac{1}{2}ln(|\Sigma 2|)$$

$$-\frac{1}{2}\left(x - \begin{bmatrix} 2 \\ 3 \end{bmatrix}\right)^T \frac{1}{1.75}\begin{bmatrix} 1 & -0.5 \\ -0.5 & 2 \end{bmatrix}\left(x - \begin{bmatrix} 2 \\ 3 \end{bmatrix}\right) + ln(P\omega 1) - \frac{1}{2}ln(1.75) = -\frac{1}{2}\left(x - \begin{bmatrix} 4 \\ 4 \end{bmatrix}\right)^T \frac{1}{1.11}\begin{bmatrix} 0.8 & 0.3 \\ 0.3 & 1.5 \end{bmatrix}\left(x - \begin{bmatrix} 4 \\ 4 \end{bmatrix}\right) + ln(P\omega 2) - \frac{1}{2}ln(1.11)$$

$$-\frac{1}{2}(x - \begin{bmatrix} 2 \\ 3 \end{bmatrix})^T \frac{1}{1.75}\begin{bmatrix} 1 & -0.5 \\ -0.5 & 2 \end{bmatrix}(x - \begin{bmatrix} 2 \\ 3 \end{bmatrix}) + ln(P\omega 1) - \frac{1}{2}ln(1.75) = -\frac{1}{2}(x - \begin{bmatrix} 4 \\ 4 \end{bmatrix})^T \frac{1}{1.11}\begin{bmatrix} 0.8 & 0.3 \\ 0.3 & 1.5 \end{bmatrix}(x - \begin{bmatrix} 4 \\ 4 \end{bmatrix}) + ln(P\omega 2) - \frac{1}{2}ln(1.11)$$

$$0.0746461\,x^2 + 0.555985\,x\,y - 3.67825\,x + 1.2471\,y^2 - 7.05792\,y = ln(\frac{P(\omega 2)}{P(\omega 1)}) - 16.1019$$

Λύνοντας την παραπάνω εξίσωση βρίσκουμε την επιφάνεια απόφασης.

Χρησιμοποιήσαμε Matlab για να σχεδιάσουμε τις ισοϋψείς καμπύλες των δύο κατανομών $p(x|\omega i\ ) \in \mathbb{R}^2$ για κάθε κλάση i.

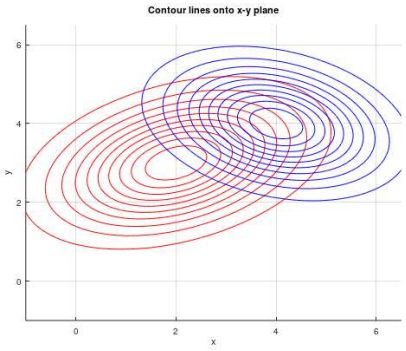

Έπειτα, σχεδιάσαμε στην ίδια εικόνα τα σύνορα απόφασης για τις ακόλουθες τιμές της εκ των προτέρων πιθανότητας $P(\omega 1)$ = 0.1, 0.25, 0.5, 0.75, 0.9 .

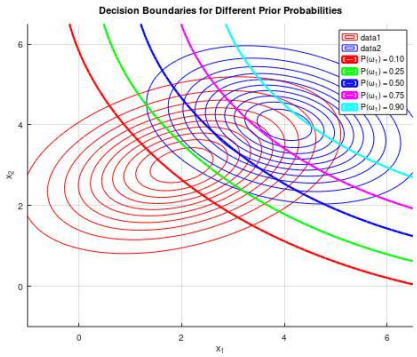

Παρατηρούμε ότι τα σύνορα απόφασης είναι ελλειπτικής μορφής κάτι που επιβεβαιώνεται και από την εξίσωση του συνόρου απόφασης. Επίσης, το σύνορο απόφασης επηρεάζεται από τις διαφορετικές τιμές της εκ των προτέρων πιθανότητας ως εξής:

- Όταν η εκ των προτέρων πιθανότητα $P(\omega 1)$ αυξάνεται, αυτό σημαίνει ότι το σύστημα αναμένει περισσότερα δείγματα να ανήκουν στην κατηγορία $\omega 1$. Για να εξισορροπήσει αυτή την υψηλότερη αναμενόμενη συχνότητα της κατηγορίας $\omega 1$, το σύνορο απόφασης μετατοπίζεται προς την κατηγορία $\omega 2$, έτσι ώστε περισσότερα δείγματα να ταξινομούνται στην κατηγορία ω1.

- Αντίθετα, όταν η εκ των προτέρων πιθανότητα $P(\omega 1)$ είναι χαμηλή, το σύνορο απόφασης μετατοπίζεται προς την κατηγορία $\omega 1$, έτσι ώστε περισσότερα δείγματα να ταξινομούνται στην κατηγορία ω2.

Αν Σ_1=$\mathbf{\Sigma}_2 = \begin{bmatrix} 1.2 & 0.4 \\ 0.4 & 1.2 \end{bmatrix}$ γνωρίζουμε από την θεωρία ότι:

$x_0 = \frac{1}{2}(\mu 1 + \mu 2) - ln(\frac{P(\omega 1)}{P(\omega 2)}) \frac{\mu 1 - \mu 2}{||\mu 1 - \mu 2||^2 \Sigma^{-1}}$, όπου $||x||\Sigma^{-1} = (x^T \Sigma^{-1} x)^{\frac{1}{2}}$

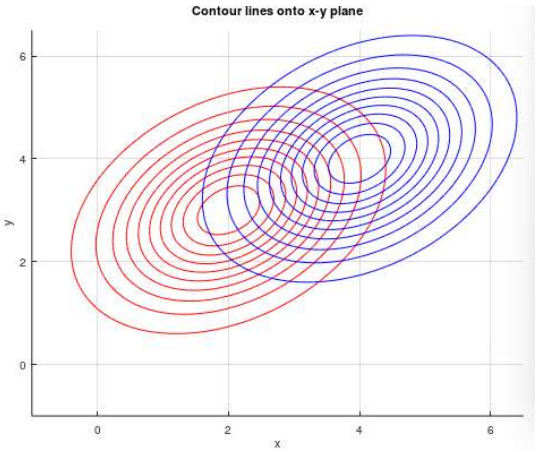

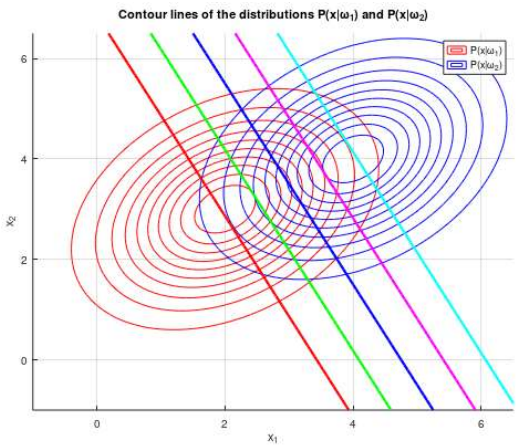

Παρατηρούμε ότι τα σύνορα απόφασης είναι γραμμικής μορφής το οποίο είναι λογικό καθώς στην θεωρία μάθαμε πως όταν $\Sigma_1 = \Sigma_2 = \Sigma$ τότε τα σύνορα απόφασης είναι γραμμικής μορφής. Επιπλέον, το σύνορο απόφασης επηρεάζεται από τις διαφορετικές τιμές της εκ των προτέρων πιθανότητας με τον ίδιο τρόπο όπως αναλύσαμε προηγουμένως.

Θέμα 5: Εξαγωγή χαρακτηριστικών και Bayes Classification.

Αρχικά, υπολογίσαμε τον λόγο όψεως (aspect ratio) όπως ορίζεται πιο πάνω για κάθε εικόνα που ανήκει στις κλάσεις $C1$ και $C2$ στο train και testset και σχεδιάσαμε δύο δείγματα από το dataset μαζί με ένα παραλληλόγραμμο (bounding box) στα όρια του aspect ratio που υπολογίσαμε.

```
Total Minimum aspect ratio: 0.15
Total Maximum aspect ratio: 2.0
```

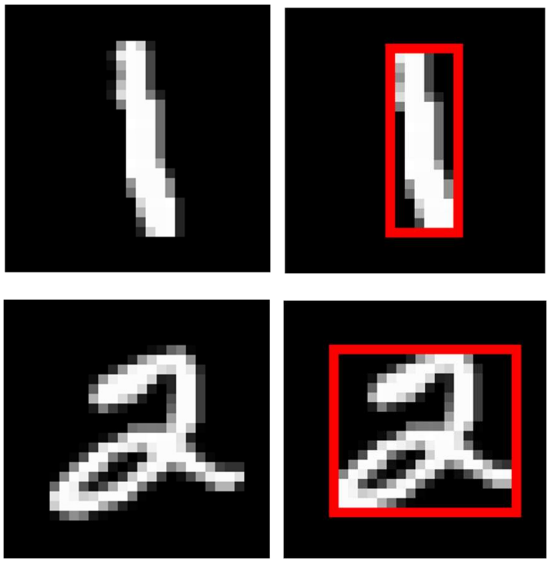

Η τιμή του total minimum aspect ratio δηλώνει ότι έχουμε ένα ψηλό και στενό bounding box (bounding box για ψηφίο 1). Αντίθετα, το total maximum aspect ratio δηλώνει ότι έχουμε ένα κοντό και πλατύ bounding box (bounding box για ψηφίο 2).

Πριν χρησιμοποιήσουμε το χαρακτηριστικό, εφαρμόσαμε min-max κανονικοποίηση στο aspect ratio στο διάστημα [-1, 1] συμπληρώνοντας κατάλληλα τη συνάρτηση min_max_scaling.

```
def min_max_scaling(X, min_val=-1, max_val=1):
    """Scales features to a range between min_val and max_val."""
    #### ADD YOUR CODE HERE #####
    X_scaled = (X - X.min()) / (X.max() - X.min()) * (max_val - min_val) + min_val
    return X_scaled
```

Στη συνέχεια, υπολογίσαμε τις εκ των προτέρων πιθανότητες $P(C1)$ και $P(C2)$ από τα δείγματα, συμπληρώνοντας τον κώδικα στη μέθοδο train της κλάσης "MyBayesClassifier". Χρησιμοποιήσαμε τις συναρτήσεις mean και cov ώστε το aspect ratio σε κάθε κλάση να ακολουθεί κανονική κατανομή και εκπαιδεύσαμε έναν Bayes ταξινομητή στη μέθοδο train.

Έπειτα, συμπληρώσαμε τις μεθόδους predict, predict_instance, calculate_1 και calculate_likelihood_1D ώστε να βρούμε ποια είναι η πρόβλεψη της κλάσης στα δείγματα ελέγχου χρησιμοποιώντας τον ταξινομητή που εκπαιδεύσαμε.

Παρακάτω εκτυπώσαμε την ακρίβεια ταξινόμησης στο σύνολο των δειγμάτων ελέγχου.

```
Classification accuracy: 0.9545454545454546
```

Η ακρίβεια ταξινόμησης είναι 95.45%. Αυτό σημαίνει ότι το μοντέλο μας έχει κατατάξει σωστά το 95.45% των δειγμάτων ελέγχου στις σωστές κατηγορίες. Μια ακρίβεια πάνω από το 90% συνήθως θεωρείται αξιόπιστη.

Επιπλέον, προσθέσαμε ως νέο χαρακτηριστικό τον αριθμό των μη μαύρων pixels που σχηματίζουν τον αριθμό σε κάθε εικόνα (foreground_pixels) και επαναλάβαμε την διαδικασία εκπαίδευσης του Bayes ταξινομητή κάνοντας την υπόθεση ότι τα χαρακτηριστικά είναι ανεξάρτητα μεταξύ τους.

```
Classification accuracy: 0.9628099173553719
```

Είναι λογικό να αυξάνεται η ακρίβεια με την προσθήκη ενός νέου χαρακτηριστικού στο μοντέλο. Αυτό συμβαίνει γιατί το νέο χαρακτηριστικό φέρει επιπλέον πληροφορία που ήταν προηγουμένως απουσιάζουσα από το μοντέλο βοηθώντας έτσι τον ταξινομητή να διαχωρίσει καλύτερα τις διαφορετικές κλάσεις.

Τέλος, προσθέσαμε ως τρίτο χαρακτηριστικό την τιμή του κεντροειδούς (κέντρο μάζας των μη μηδενικών pixels) συμπληρώνοντας την συνάρτηση calculate_centroid και επαναλάβαμε την διαδικασία εκπαίδευσης του Bayes ταξινομητή.

```
Classification accuracy: 0.9669421487603306
```

Η αύξηση της ακρίβειας με την προσθήκη ενός νέου χαρακτηριστικού στο μοντέλο είναι αναμενόμενη, καθώς το νέο χαρακτηριστικό φέρνει επιπλέον πληροφορία που μπορεί να βοηθήσει το μοντέλο να κατανοήσει καλύτερα τα δεδομένα. Ωστόσο, η ακρίβεια αυξήθηκε ελάχιστα, καθώς το νέο χαρακτηριστικό δεν πρόσφερε τόσο σημαντική πληροφορία όσο το αρχικό χαρακτηριστικό (π.χ. aspect ratio). Αυτό μπορεί να οφείλεται στο γεγονός ότι το νέο χαρακτηριστικό δεν έχει τόσο μεγάλη επίδραση στην τελική ταξινόμηση.

Επαναλάβαμε τα παραπάνω θεωρώντας ότι έχουμε τρεις κλάσεις και συγκεκριμένα τα ψηφία 0, 1, 2.

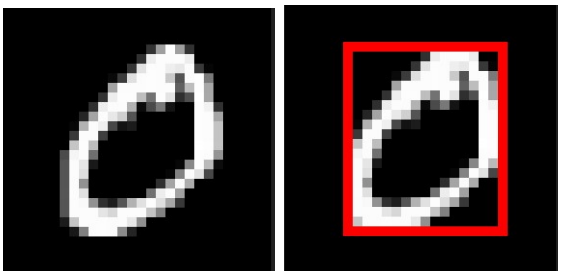

Έχοντας ως μόνο χαρακτηριστικό το aspect ratio εκτυπώσαμε την ακρίβεια του ταξινομητή.

```
Classification accuracy: 0.7155963302752294
```

Όταν επεκτείνουμε την ανάλυση μας για να περιλαμβάνει τρεις κλάσεις, συγκεκριμένα τα ψηφία 0, 1, και 2, παρατηρούμε ότι η ακρίβεια του ταξινομητή μειώνεται σε σύγκριση με την περίπτωση που ταξινομούμε μόνο δύο κλάσεις (π.χ., 1 και 2). Αυτό συμβαίνει καθώς η προσθήκη μιας νέας κλάσης αυξάνει την πολυπλοκότητα του προβλήματος ταξινόμησης. Επίσης, έχουμε μεγαλύτερη επικάλυψη χαρακτηριστικών, καθιστώντας την διάκριση μεταξύ τους πιο δύσκολη.

```
Classification accuracy: 0.7155963302752294
```

Αν προσθέσουμε ως νέο χαρακτηριστικό τον αριθμό των μη μαύρων pixels που σχηματίζουν τον αριθμό σε κάθε εικόνα, η ακρίβεια παραμένει ίδια που σημαίνει ότι η προσθήκη του νέου χαρακτηριστικού δεν μπόρεσε να βοηθήσει περισσότερο τον ταξινομητή στο να διαχωρίσει τις κλάσεις.

```
Classification accuracy: 0.7155963302752294
```

Τέλος, αν προσθέσουμε ως τρίτο χαρακτηριστικό την τιμή του κεντροειδούς παρατηρούμε ότι η ακρίβεια παραμένει ξανά ίδια που σημαίνει ότι ούτε αυτό το χαρακτηριστικό κατάφερε να βοηθήσει περισσότερο τον ταξινομητή στο να διαχωρίσει τις κλάσεις.

```
Classification accuracy: 0.7155963302752294
```

<u>Σημείωση:</u>

Αν δοκιμάσουμε το ίδιο με άλλα ψηφία (π.χ. το 1,2,9) παρατηρούμε ότι η ακρίβεια αυξάνεται με τις προσθέσεις νέων χαρακτηριστικών.

Έχοντας μόνο το aspect ratio:

```
Classification accuracy: 0.7083333333333334
```

Έχοντας το aspect ratio, fg_pixels:

```
Classification accuracy: 0.7113095238095238
```

Έχοντας το aspect ratio, fg_pixels, centroid:

```
Classification accuracy: 0.7202380952380952
```

Θέμα 6: Minimum risk

Έχουμε δύο κλάσεις ω_1 και ω_2 που οι εκ των προτέρων πιθανότητες είναι ίσες $P(\omega_1) = P(\omega_2) = \frac{1}{2}$. Τα δείγματα x που πρέπει να κατηγοριοποιηθούν ακολουθούν κατανομή Rayleigh με συνάρτηση πυκνότητας πιθανότητας που δίνεται από την ακόλουθη σχέση:

$$p(x|\omega_i) = \begin{cases} \frac{x}{\sigma_i^2} e^{-\frac{x^2}{2\sigma_i^2}} & x \geq 0 \\ 0, & x < 0 \end{cases}$$

Με $\sigma_1 = 1$ και $\sigma_2 = 2$ και ο πίνακας ρίσκου είναι:

$$\boldsymbol{L} = \begin{pmatrix} \lambda 11 & \lambda 12 \\ \lambda 21 & \lambda 22 \end{pmatrix} = \begin{pmatrix} 0 & 0.5 \\ 1 & 0 \end{pmatrix}$$

<u>Μέσο Ρίσκο</u>

r = $r1P(\omega 1) + r2P(\omega 2)$

Όπου $r1 = \lambda 11 \int_{R1} p(x|\omega 1)dx + \lambda 12 \int_{R2} p(x|\omega 1)dx = \lambda 12 \int_{R2} p(x|\omega 1)dx$, αφού $\lambda_{11} = 0$

και $r2 = \lambda 21 \int_{R1} p(x|\omega 2)dx + \lambda 22 \int_{R2} p(x|\omega 2)dx = \lambda 21 \int_{R1} p(x|\omega 2)dx$, αφού $\lambda_{22} = 0$

Συνεπώς έχουμε:

$$r = (\lambda 12 \int_{R2} p(x|\omega 1)dx)\, P(\omega 1) + (\lambda 21 \int_{R1} p(x|\omega 2)dx)\, P(\omega 2) =$$

$$= \int_{R2} (\lambda 12 p(x|\omega 1)P(\omega 1))\, dx + \int_{R1} (\lambda 21 p(x|\omega 2)\, P(\omega 2))\, dx$$

<u>*Likelihood Ratios*</u>

Έχουμε $\lambda_{11} = \lambda_{22} = 0$, οπότε αναθέτουμε το <u>x</u> στο ω_1 αν $\frac{p(x|\omega 1)}{p(x|\omega 2)} > \frac{P(\omega 2)\lambda 21}{P(\omega 1)\lambda 12}$,

Ενώ αναθέτουμε το <u>x</u> στο ω_2 αν $\frac{p(x|\omega 1)}{p(x|\omega 2)} < \frac{P(\omega 2)\lambda 21}{P(\omega 1)\lambda 12}$.

Η threshold τιμή $\widehat{x_0}$ για το ελάχιστο r είναι ίση με:

$\widehat{x_0}$: r1 = r2

$\widehat{x_0}$: λ_{12} P(x|ω_1) = λ_{21} P(x|ω_2)

$\widehat{x_0}$: $\frac{x}{\sigma 1^2} e^{-\frac{x^2}{2\sigma 1^2}} = 2\frac{x}{\sigma 2^2} e^{-\frac{x^2}{2\sigma 2^2}}$

$\widehat{x_0}$: $x\, e^{-\frac{x^2}{2}} = \frac{x}{2} e^{-\frac{x^2}{8}}$

$\widehat{x_0}$: $\pm 2\sqrt{\frac{2log(2)}{3}}$ = $2\sqrt{\frac{2log(2)}{3}}$, αφού P(x|$\omega i$) = 0 για x < 0